一、理论证明

两层 ReLU 神经网络可以表示为:

$$f(x) = \sum_{i=1}^{N} a_i \cdot \sigma(w_i x + b_i), \sigma(x) = max(0, x)$$

由于 ReLU 函数是分段线性函数，多个 ReLU 函数的线性组合仍然是分段线性函数，因此两层 ReLU 神经网络本质上可以表示为分段线性函数。每个 ReLU 单元可以在输入空间中引入一个“折点”，通过调整参数可以控制各段的斜率和位置，从而构造出任意形状的折线函数。根据数学分析中的结论：任意连续函数都可以用分段线性函数在任意精度下逼近。因此，对于任意连续函数$f(x)$和任意精度ε>0，都可以通过增加隐藏层神经元数量，使 ReLU 网络构造出足够多的线性片段，从而逼近该函数。

因此可以得出结论：当隐藏层神经元数量足够多时，两层 ReLU 神经网络可以以任意精度逼近任意连续函数。

二、函数定义

2.1 目标函数

实验选择的拟合的函数为：f(x) = sin(2πx) + 0.3·sin(6πx)， x∈[-1, 1]

这是一个由两个不同频率正弦波叠加而成的复合函数，具有多个局部极值点，能够有效测试神经网络的拟合能力。

2.2 损失函数

采用均方误差（Mean Squared Error, MSE）作为损失函数： $L = (1/n)\Sigma\left(y_{pred} - y_{true}\right)^2$

三、数据采集

3.1 训练数据

采样点数共 500 个, 采样范围为 x ∈ [-1, 1], 噪声水平方面添加标准差为 0.03 的高斯噪声，便于模拟真实场景中的观测误差，提高模型泛化能力。

3.2 测试数据

采样点数共 200 个，采样范围为 x ∈ [-1, 1]，不添加噪声，以评估模型在纯净数据上的真实拟合能力。

3.3 数据预处理

训练前对输入数据 x 进行标准化$x_{normalized} = (x - mean)/std$，加速训练收敛，提高数值稳定性。

四、模型描述

4.1 网络结构

采用两层全连接神经网络：输入层 1 个神经元；隐藏层 32 个神经元，选用 ReLU 激活函数；输出层 1 个神经元，线性激活（回归任务）。

4.2 数学表达

前向传播过程：$h = ReLU(W_1x + b_1)$ $\hat{y} = W_2h + b_2$

其中：W_1 (1×32), b_1 (1×32) 为第一层参数，W_2 (32×1), b_2 (1×1) 为第二层参数

4.3 优化算法

优化器选用小批量随机梯度下降（Mini-batch SGD），学习率: 0.01，批量大小: 32，迭代次数: 3000，梯度裁剪: 1.0（防止梯度爆炸）

五、拟合效果

5.1 定量评估

MSE=0.016851，MAE=0.091699，模型具有良好的拟合精度。

5.2 误差分析

误差均值: 0.028668，说明模型在整体上没有明显的系统性偏差

误差标准差: 0.126606，正常

误差范围: [-0.436937, 0.543832]，存在误差较大的情况，主要出现在波峰和波谷，在线性函数拟合曲线函数中属于正常情况。

5.3 可视化分析

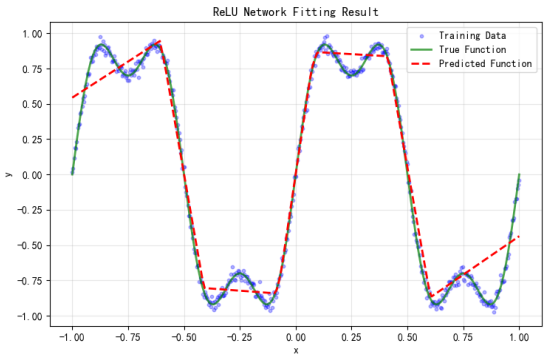

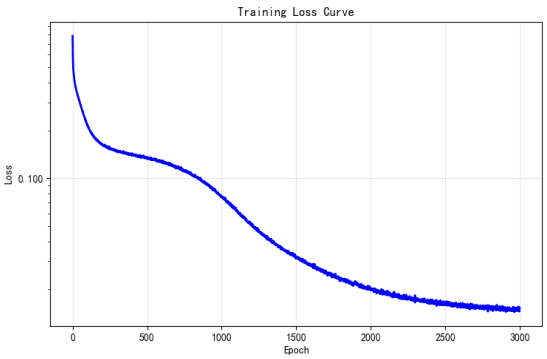

从图中可以看出，红色虚线（预测值）与绿色实线（真实函数）大部分都重合，但在函数变化剧烈的区域（如波峰和波谷）预测精度较低；蓝色散点（训练数据）围绕真实函数波动，体现了添加的噪声。

从损失曲线上可以看出损失值快速下降，2000epoches 后损失降至 0.02 以下，曲线平滑下降，没有明显震荡，说明学习率选择合适。

5.4 隐藏层分析

激活率约 42.78%（ReLU 神经元激活的比例），输出均值: 0.2312，输出标准差: 0.3691

隐藏层神经元激活率适中，表明网络有效利用了神经元资源，能力和泛化能力较为均衡。